

Estrategia de Optimización de Costos y Recursos

Contexto y alcance

Este proyecto se desarrolló como pieza de portfolio, con volumen bajo (pruebas manuales y un puñado de licitaciones reales por corrida). Para el desarrollo se utilizó Google Gemini de forma exclusiva, accediendo sin costo a través de la capa gratuita de la API disponible en la cuenta de Google AI Studio, lo que permitió iterar y probar el flujo completo sin generar gasto durante el curso. Esta sección documenta esa decisión, sus limitaciones frente a un escenario de producción real, y qué optimizaciones de costo están efectivamente implementadas en el flujo actual.

Cuadro comparativo de modelos (precios oficiales, USD por millón de tokens, septiembre 2026)

Modelo	Input (USD/1M)	Output (USD/1M)	Rol típico
Gemini 3.5 Flash-Lite	\$0.30	\$2.50	Tareas mecánicas / clasificación simple
Gemini 3 Flash (usado en el proyecto)	\$0.75	\$3.75	Extracción y análisis (uso actual)
GPT-4o-mini	\$0.15	\$0.60	Tareas mecánicas de bajo costo
Claude Haiku 4.5	\$1.00	\$5.00	Lectura densa de complejidad media
Claude Sonnet 5	\$2.00	\$10.00	Lectura densa / razonamiento complejo

Matriz de decisión estratégica

Criterio	Gemini (elegido)	Alternativa multi-modelo (GPT-4o-mini + Claude)
Costo de desarrollo	\$0 (capa gratuita)	Requiere cuenta de facturación activa en 2 proveedores
Complejidad de implementación	1 solo modelo, 1 sola credencial	2 modelos, lógica de enrutamiento según tipo de tarea
Costo en producción (estimado)	~\$0.0045 por licitación procesada	~\$0.0008-0.003 por licitación (según reparto de tareas)
Confiabilidad observada	Falla ocasional por saturación del tier gratuito (ver Seguridad/Resiliencia)	Mayor estabilidad esperada con cuenta de pago
Adecuación al alcance del proyecto	Alta — volumen bajo, portfolio	Sobre-ingeniería para este volumen

Decisión: para el alcance de este proyecto (portfolio, volumen bajo, sin presupuesto asignado), un único modelo (Gemini) resulta la opción más simple y de menor fricción, aun sin ser la más económica por token frente a GPT-4o-mini. La arquitectura multi-modelo (tarea mecánica → modelo económico, lectura densa → modelo de mayor capacidad, procesamiento masivo → Batch API) es la

recomendación correcta para un escenario de producción con volumen alto, pero no se justifica a esta escala.

Optimización de recursos ya implementada en el flujo actual

Aunque no hay reparto entre modelos, el flujo sí aplica optimización de costo real en dos puntos:

- Filtro gratuito antes de la IA: el nodo Filter (palabra clave "licitaci") descarta contenido irrelevante del feed RSS antes de gastar una llamada a la IA — el filtrado mecánico no tiene costo, solo se invoca a Gemini con contenido que ya pasó ese primer filtro.
- Límite de tokens de salida: el nodo de IA está configurado con Max Tokens = 800, evitando respuestas innecesariamente largas que encarecerían cada llamada sin aportar valor al dato estructurado que se necesita.

Ejemplo numérico de costo estimado

Para una licitación típica (~3.000 tokens de entrada entre prompt + texto extraído del aviso, ~600 tokens de salida):

Modelo	Costo por licitación	Costo estimado / 1.000 licitaciones
Gemini 3 Flash (actual)	~\$0.0045	~\$4.50
GPT-4o-mini	~\$0.0008	~\$0.80
Claude Haiku 4.5	~\$0.006	~\$6.00

Escenario de producción real

Si el volumen creciera a un ritmo de producción (cientos de licitaciones diarias), lo que haria sería: mantener el filtro de palabras clave gratuito como primera capa, usar un modelo económico (GPT-4o-mini o Gemini Flash-Lite) para una clasificación rápida de relevancia antes del análisis completo, y reservar un modelo de mayor capacidad solo para las licitaciones que superen ese primer filtro, evaluando la API de lotes (Batch) si el volumen lo justifica.